

FEDMD

HETEROGENOUS FEDERATE LEARNING
VIA MODEL DISTILLATION

REFERENCE

- ▶ Li, Daliang, and Junpu Wang.
"Fedmd: Heterogenous federated learning via model distillation."
arXiv preprint arXiv:1910.03581 (2019).

ABSTRACT

ABSTRACT

- ▶ 연합 학습은
 - ▶ 다양한 참여자의 데이터 프라이버시를 훼손하지 않으면서
 - ▶ 강력한 중앙화된(하나의) 모델을 형성하는 방법
- ▶ 그러나 참가자들이 각자의 모델을 설계하도록 협력하지는 못함

ABSTRACT

- ▶ 저자들은 **전이 학습(transfer learning)**과 **모델 증류(model distillation)**를 사용해
 - ▶ 각 참여자의 데이터 프라이버시를 지키며
 - ▶ 또한 독자적으로 모델을 디자인할 수 있는
 - ▶ 연합 학습 프레임워크를 제안
- ▶ 모델 증류
 - ▶ 미리 학습시킨 Teacher network 의 출력을
 - ▶ 다른 (작은) 모델인 Student network 가 모방하여 학습

INTRODUCTION

INTRODUCTION

- ▶ 연합 학습은 많은 도전에 직면해 있음
 - ▶ 학습 과정에 걸친 이종성이 문제
- ▶ 이종성
 - ▶ 데이터의 이종성은 물론이고
 - ▶ 각 참여자의 대역폭이 다르고
 - ▶ 연산력도 다름

INTRODUCTION

- ▶ 기존의 연합 학습에서는
 - ▶ 모든 유저가 중앙화된 모델 구조에 대해 (암묵적으로) 동의한 것
- ▶ 본 논문에서는 또 다른 종류의 이종성에 집중
 - ▶ 로컬 모델의 차이

INTRODUCTION

- ▶ 본 논문에서는 연합 학습을 보다 사업적인 관점에서 해석
 - ▶ 참여자 각각이 고유의 모델을 갖고자 함
 - ▶ 헬스케어, 금융, 서플라이 체인, AI 서비스 등
- ▶ 참여자들이 모델의 디테일을 공유하고자 하지 않음
 - ▶ 프라이버시
 - ▶ 지적재산권

INTRODUCTION

- ▶ 참여자가 서로 다른 모델을 가지고
 - ▶ 상대방에게는 블랙박스로 보일 때
 - ▶ 어떻게 연합 학습을 할 수 있을까?
- ▶ FedMD

CONTRIBUTION

- ▶ FedMD
 - ▶ 참가자들이 저마다 모델을 설계할 수 있는
 - ▶ 새로운 연합 학습 프레임워크
- ▶ 중앙 서버
 - ▶ 구조에 대해 건들지 않음
 - ▶ 제한된 블랙박스 접근만을 허용

METHODS

PROBLEM DEFINITION

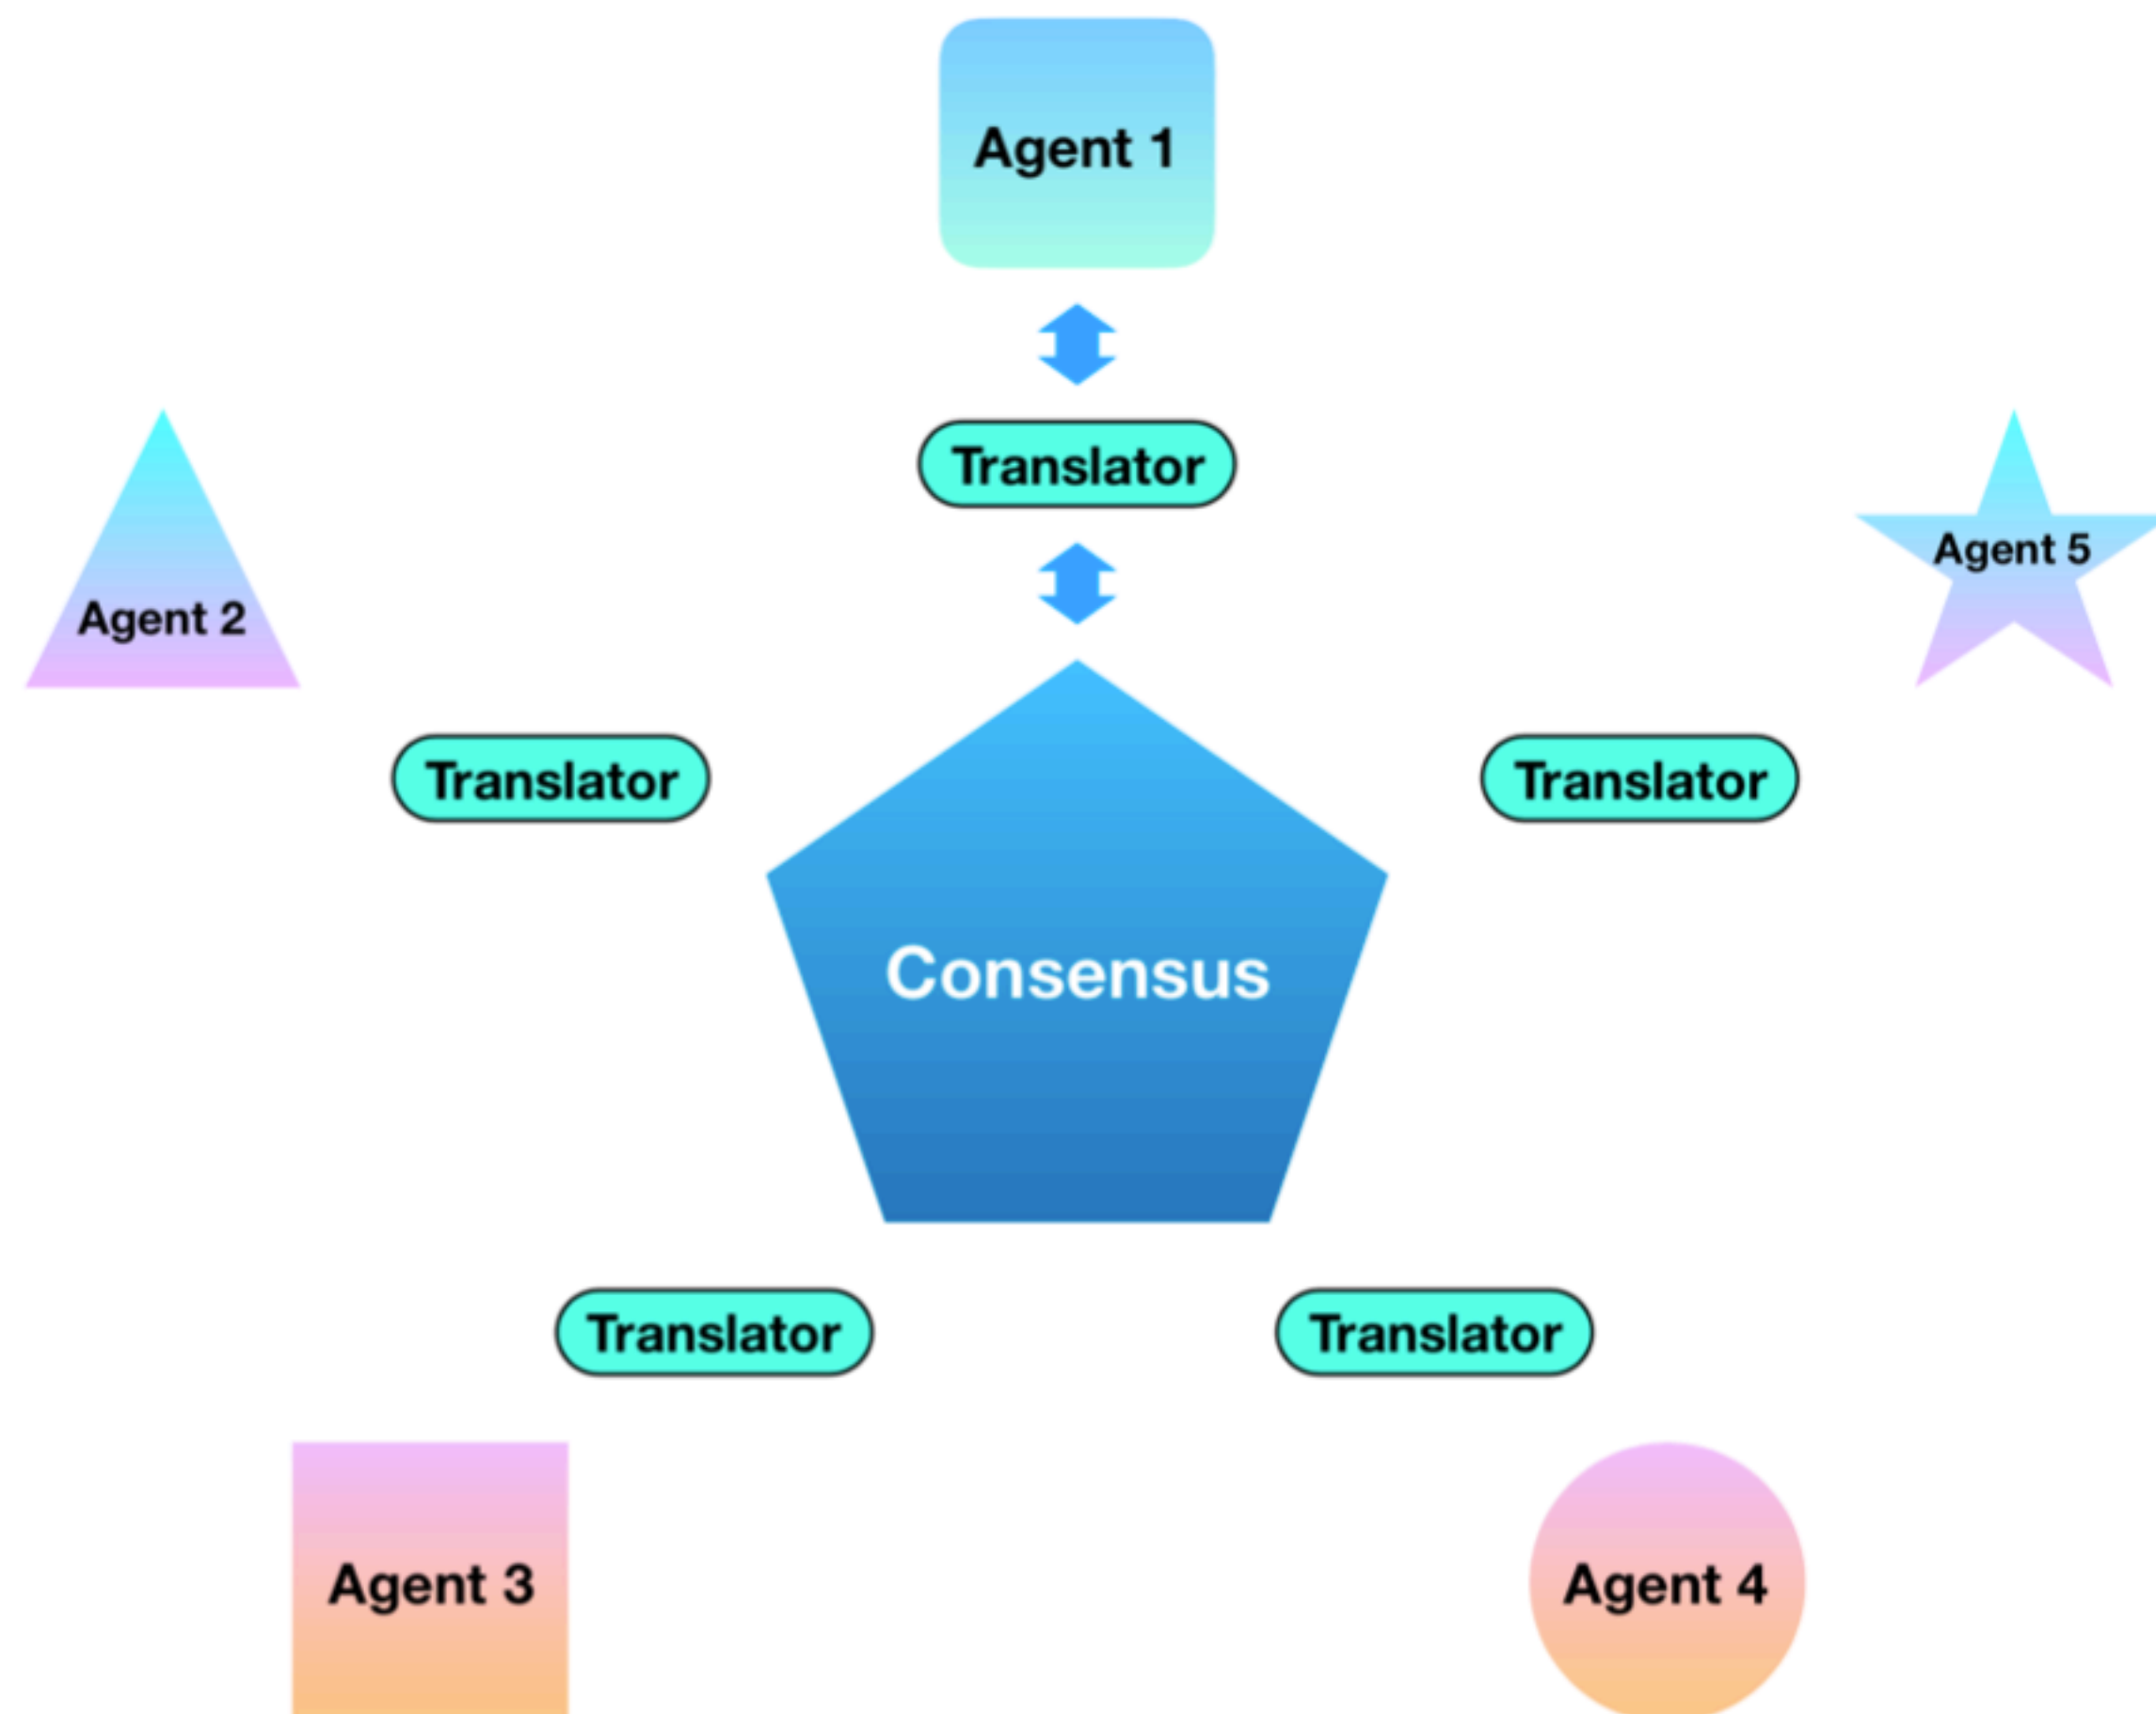
- ▶ m 명의 참가자
- ▶ 매우 작은 양의 레이블링된 데이터셋 $D_k := \{(x_i^k, y_i)\}_{i=1}^{N_k}$
 - ▶ 같은 분포를 가질 수도, 그렇지 않을 수도 있음
- ▶ 매우 많은 양의 공공(public) 데이터셋 $D_0 := \{(x_i^0, y_i^0)\}_{i=1}^{N_0}$
 - ▶ 누구나 접근할 수 있음
- ▶ 각 참가자의 독자적인 고유 모델 f_k
 - ▶ 서로 다른 구조를 가질 수 있음

PROBLEM DEFINITION

▶ 목표

- ▶ 로컬이 접근할 수 있는 데이터 D_0 와 D_k 에 대해
- ▶ (단순한 전이 학습보다 더 성능이 좋도록)
- ▶ f_k 의 성능을 향상시키는 것

THE FRAMEWORK FOR HETEROGENEOUS FEDERATED LEARNING



THE FRAMEWORK FOR HETEROGENEOUS FEDERATED LEARNING

Algorithm 1: The FedMD framework enabling federated learning for heterogeneous models.

Input: Public dataset \mathcal{D}_0 , private datasets \mathcal{D}_k , independently designed model f_k , $k = 1 \dots m$,

Output: Trained model f_k

Transfer learning: Each party trains f_k to convergence on the public \mathcal{D}_0 and then on its private \mathcal{D}_k .

for $j=1,2,\dots,P$ **do**

Communicate: Each party computes the class scores $f_k(x_i^0)$ on the public dataset, and transmits the result to a central server.

Aggregate: The server computes an updated consensus, which is an average

$$\tilde{f}(x_i^0) = \frac{1}{m} \sum_k f_k(x_i^0).$$

Distribute: Each party downloads the updated consensus $\tilde{f}(x_i^0)$.

Digest: Each party trains its model f_k to approach the consensus \tilde{f} on the public dataset \mathcal{D}_0 .

Revisit: Each party trains its model f_k on its own private data for a few epochs.

end

THE FRAMEWORK FOR HETEROGENEOUS FEDERATED LEARNING

▶ 전이 학습

- ▶ 참여자들이 협력 페이즈를 실행하기에 앞서, 모델은 전이 학습 절차를 겪어야 함
- ▶ 공공 데이터셋 전체로 학습되고, 이어 고유의 사적 데이터셋으로 학습
- ▶ 이 학습 결과가 기준점이 되어 이후의 향상들과 비교될 것

THE FRAMEWORK FOR HETEROGENEOUS FEDERATED LEARNING

- ▶ 커뮤니케이션
 - ▶ 지식 증류(knowledge distillation)를 사용할 것
 - ▶ 각 f_k 는 공공 데이터셋 D_0 로 분류 스코어 $f_k(x_i^0)$ 를 공유
 - ▶ 이로부터 지식에 대해 표출함

THE FRAMEWORK FOR HETEROGENEOUS FEDERATED LEARNING

▶ 커뮤니케이션

- ▶ 중앙 서버는 분류 스코어들을 모은 뒤 평균인 $\tilde{f}(x_i^0)$ 를 계산
- ▶ 각 참여자는 업데이트된 합의 $\tilde{f}(x_i^0)$ 를 다운로드
- ▶ 각 참여자는 업데이트된 합의 $\tilde{f}(x_i^0)$ 에 도달하기 위해 학습

RESULTS

RESULTS

- ▶ 두 서로 다른 환경에서 테스트
 - ▶ 공공 데이터셋은 MNIST, 사적 데이터셋은 FEMNIST의 서브셋
 - ▶ 공공 데이터셋은 CIFAR10, 사적 데이터셋은 CIFAR100의 서브셋
- ▶ iid 상황과 non-iid 상황 따로 고려
 - ▶ 당연히 non-iid 상황이 더 도전적인 과제임

RESULTS


- ▶ 10명의 참가자가 고유한 컨볼루션 네트워크를 가짐
 - ▶ 채널 수가 다르고 레이어 수가 다름

RESULTS

- ▶ 먼저 공공 데이터셋으로 수렴할 때 까지 학습함
- ▶ 이후 각 참여자들이 고유의 모델을 고유의 작은 사적 데이터셋으로 학습함
 - ▶ 성능의 기준선이 됨
- ▶ 이후 협력 페이즈로 진입
 - ▶ 매 라운드마다 전체 데이터셋 D_0 을 활용하는 것이 아닌
 - ▶ 서브셋 $d_j \subset D_0$ 을 활용


RESULTS

- ▶ FedMD 방법이 테스트 정확도를 향상시킴
 - ▶ 그래프에서 왼쪽에 점선으로 표시된
 - ▶ 기준선(전이 학습)을 넘어섬
- ▶ 오른쪽의 대시-점선은
 - ▶ 모든 데이터를 가지고 학습했을 경우의 성능
 - ▶ 일종의 상한의 역할

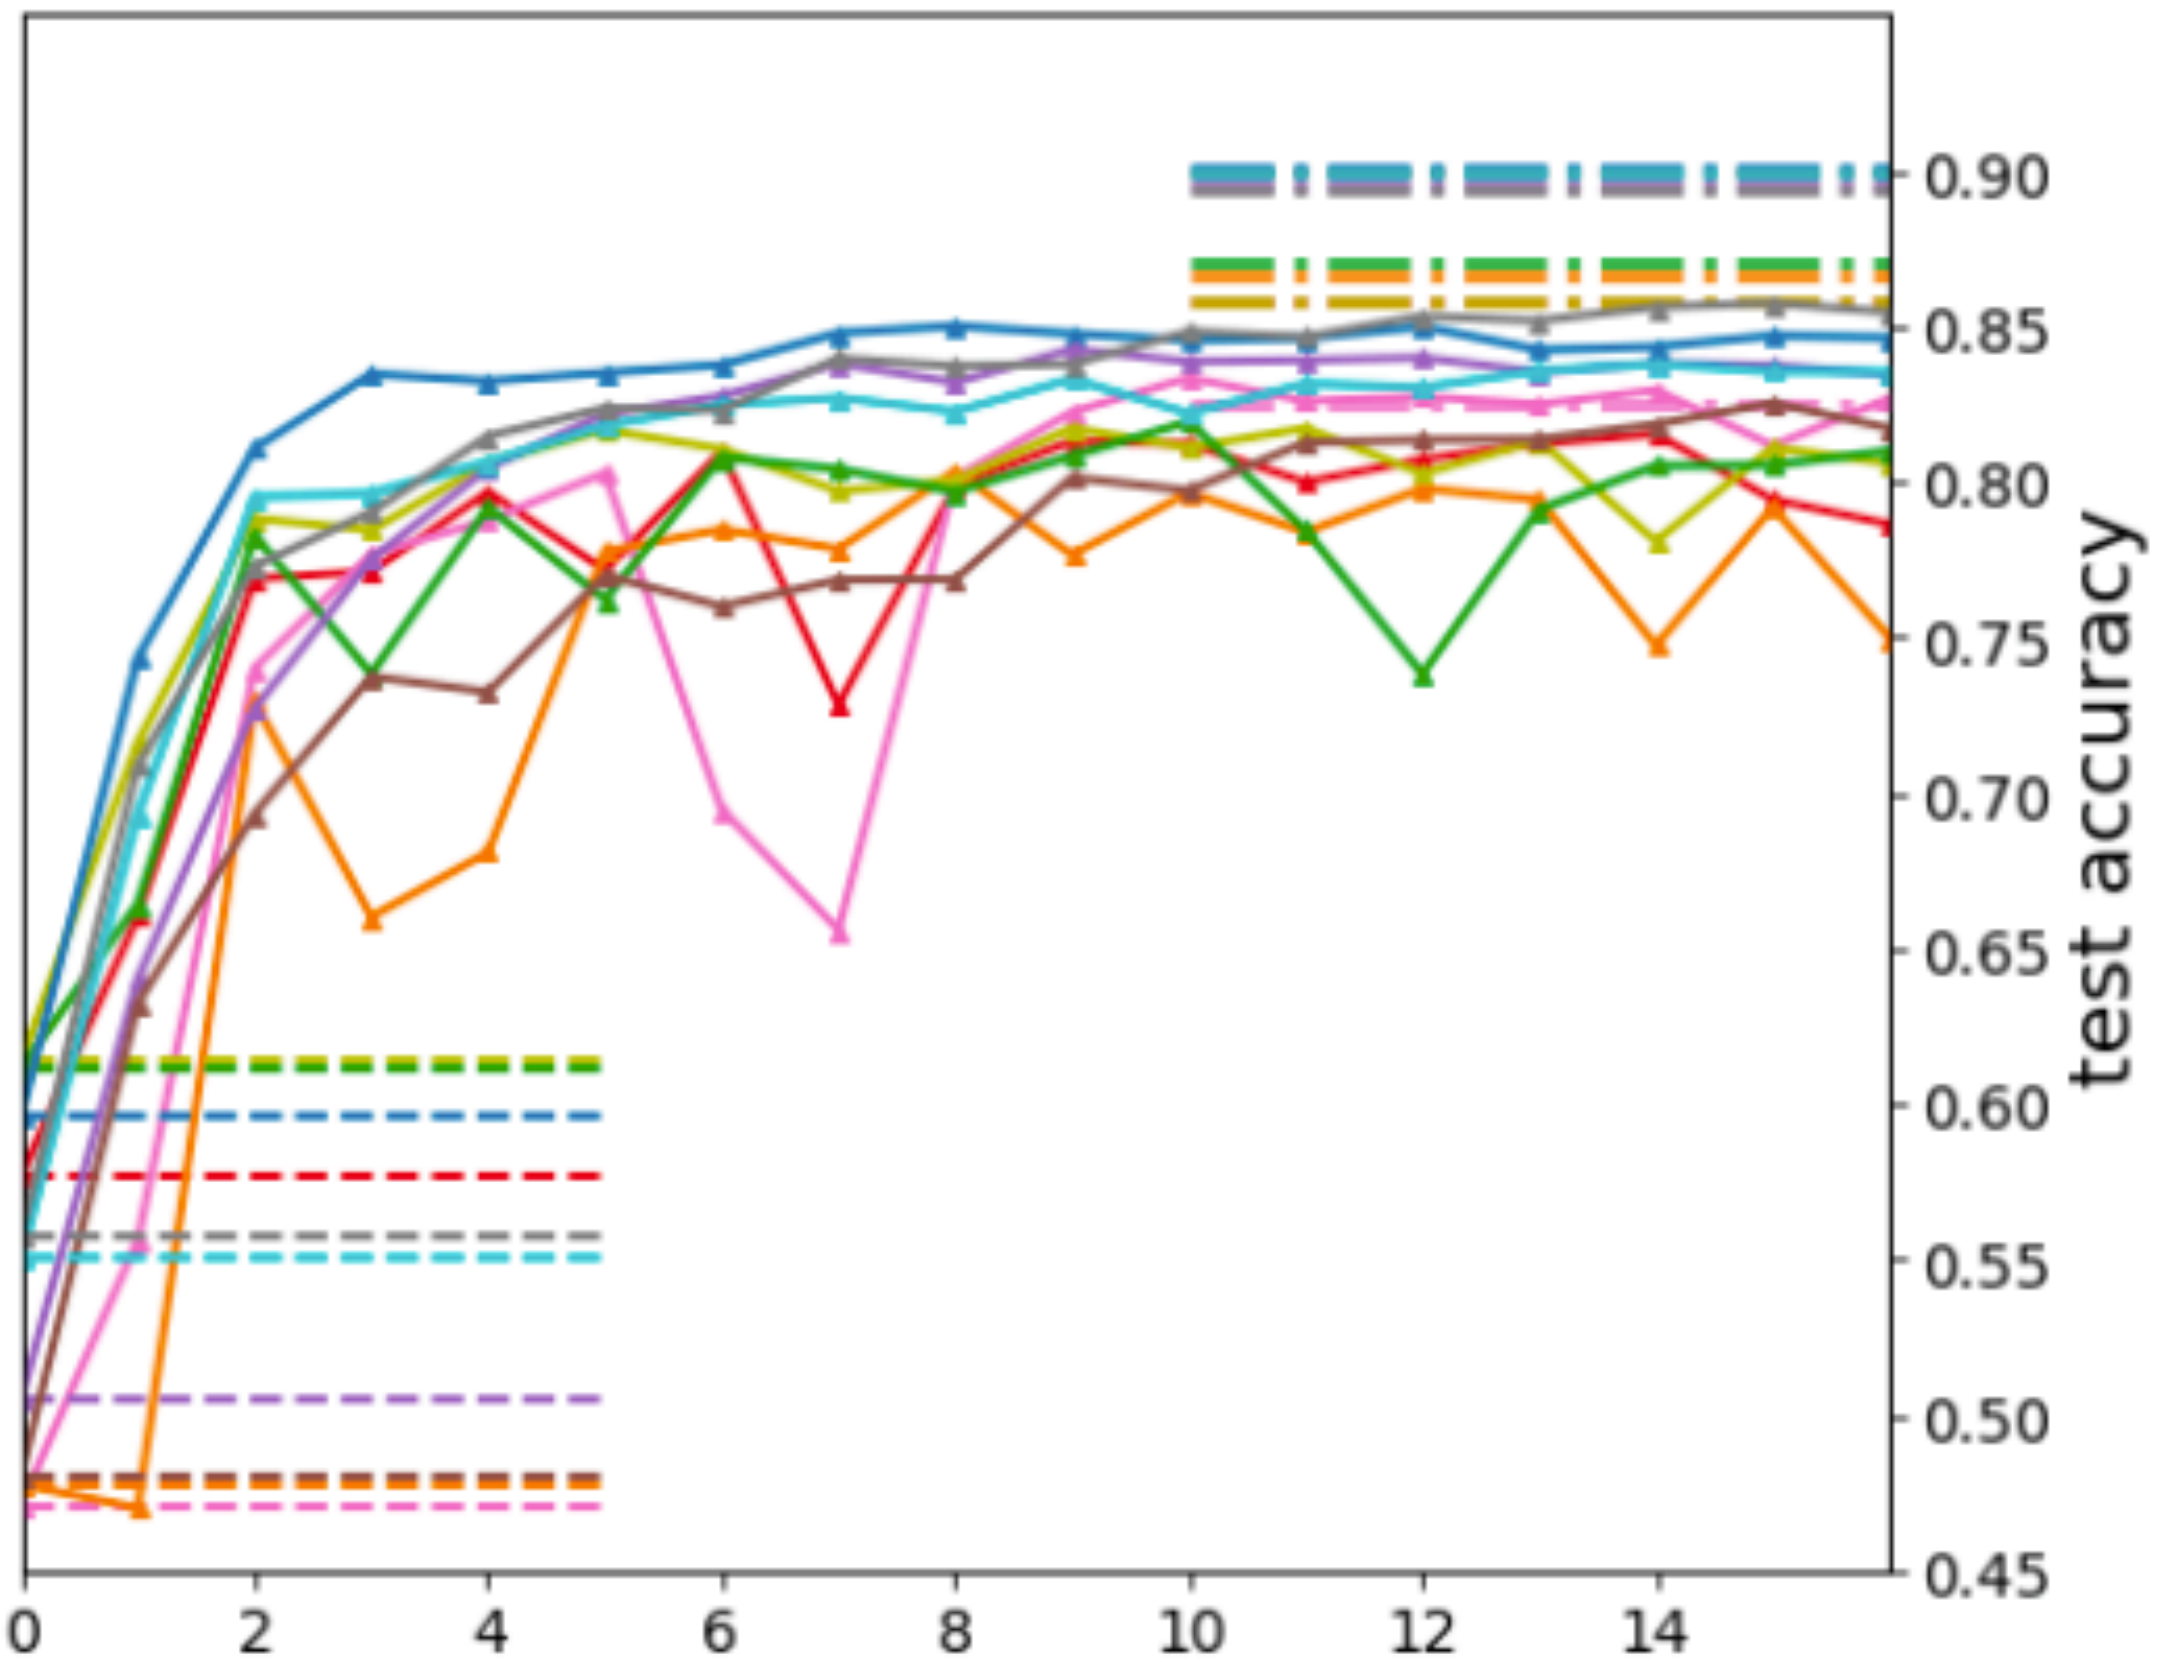


RESULTS

FEMNIST I.I.D.




FEMNIST Non I.I.D.




RESULTS

CIFAR100 I.I.D.



CIFAR100 Non I.I.D.



CONCLUSION

CONCLUSION

- ▶ FedMD
 - ▶ 서로 다른 모델을 가지고
 - ▶ 연합 학습이 가능하게 한 프레임워크
 - ▶ 전이 학습과 지식 증류에 기반

CONCLUSION

- ▶ 추후
 - ▶ Feature transformation 이나
 - ▶ Emergent communication 프로토콜 등
 - ▶ 더 세련된 커뮤니케이션 모듈을 활용할 수 있을 것
- ▶ NLP나 강화학습에도 적용할 수 있을 것

FEDMD

HETEROGENOUS FEDERATE LEARNING
VIA MODEL DISTILLATION