

STACKEDGAN

DISENTANGLED REPRESENTATIONS

REFERENCE

- ▶ Huang, Xun, et al.
"Stacked generative adversarial networks."
Proceedings of the IEEE conference on computer vision and pattern recognition. 2017.

OVERVIEW

STACKEDGAN

- ▶ 조건이 부여된 생성기 출력을 위한 잠재 표현 분해 방식


STACKEDGAN

- ▶ InfoGAN과는 달리
 - ▶ (노이즈 + 조건)을 학습하는 것이 아닌
 - ▶ GAN을 GAN의 스택으로 나눔
- ▶ 각각의 GAN은 자신만의 잠재 코드를 가지고
 - ▶ 일반적인 GAN처럼
 - ▶ 판별기-적대적 방식으로 독립적으로 훈련됨

STRUCTURE


STACKEDGAN

- ▶ 인코더(Encoder)
 - ▶ 분류를 수행하는
 - ▶ 미리 학습된
 - ▶ Bottom-up DNN




STACKEDGAN

- ▶ 생성기
 - ▶ Top-down의
 - ▶ 여러 생성기의 스택
- ▶ 각 GAN은
 - ▶ 고레벨의 특징과
 - ▶ 노이즈 벡터를 입력으로 함
 - ▶ 저레벨의 특징을 출력



STACKEDGAN

- ▶ 각 GAN을
 - ▶ 독립적으로 학습한 다음
 - ▶ E0-G0 학습 후 E1-G1 ...
- ▶ 이후 End-to-end의 관점에서
 - ▶ 함께 학습




TRAIN

SGAN TRAIN

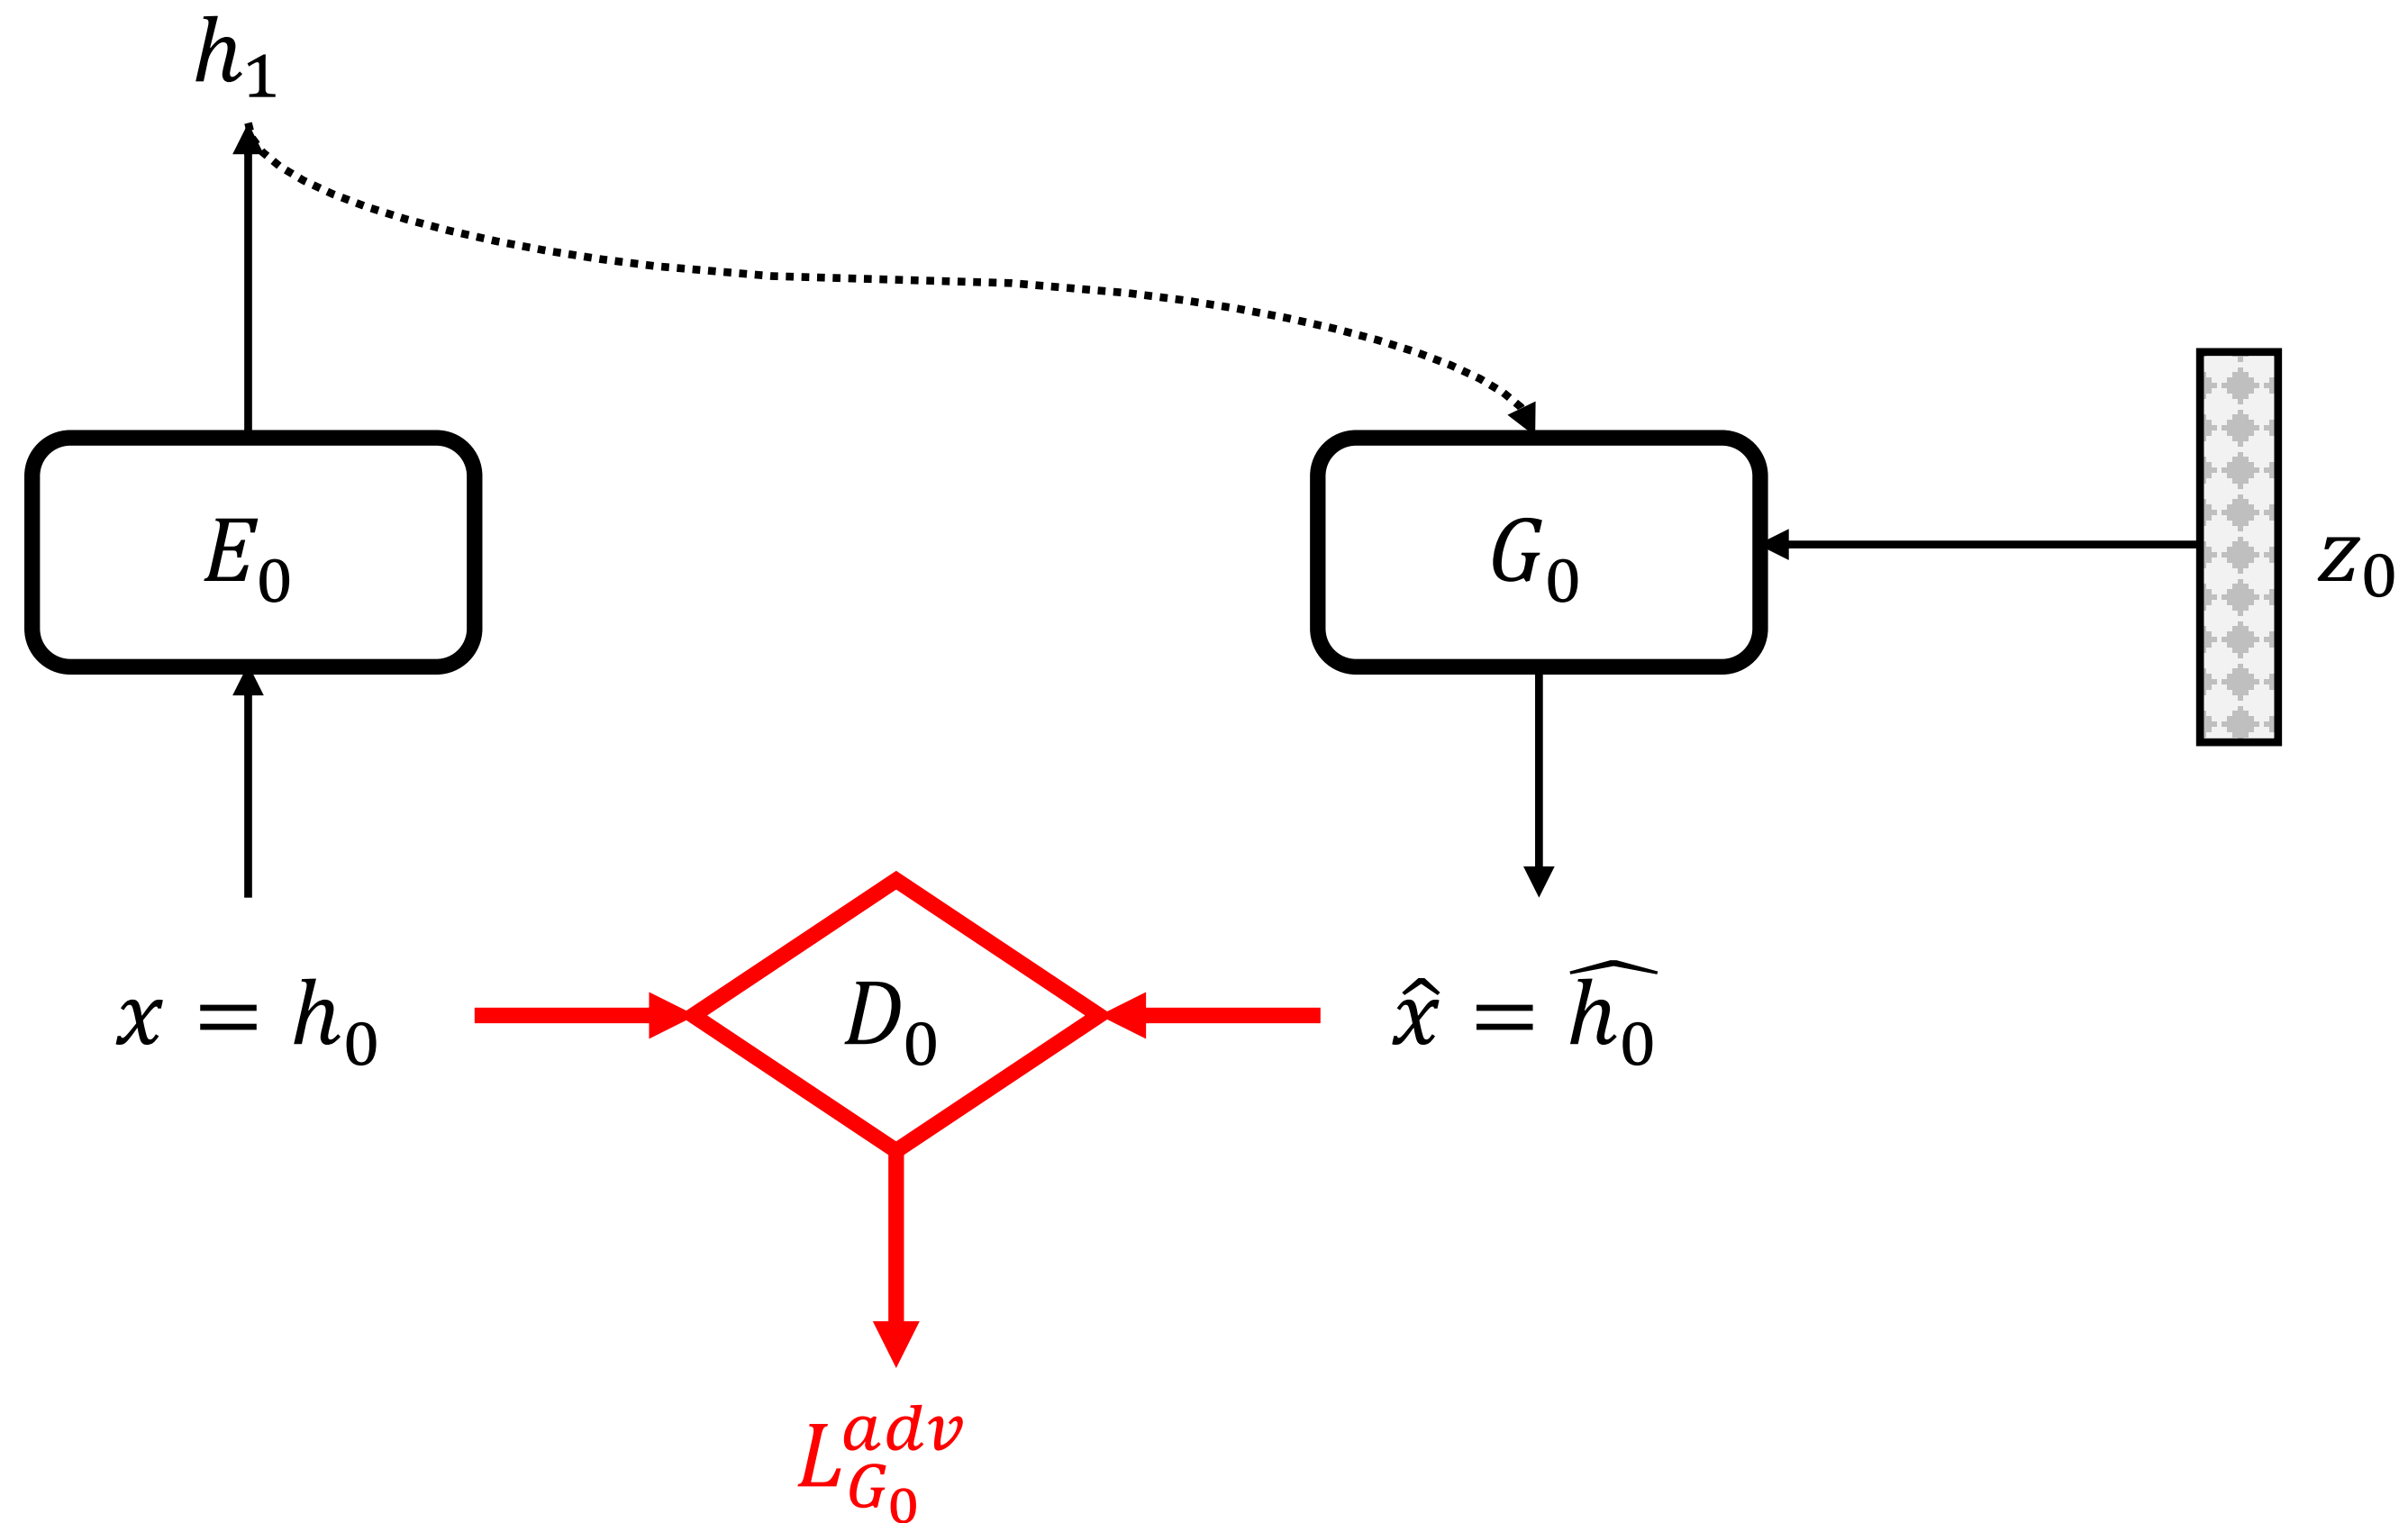
▶ 1. 각 GAN의 독립적 학습

▶ $L_{G_i} = \lambda_1 L_{G_i}^{adv} + \lambda_2 L_{G_i}^{cond} + \lambda_3 L_{G_i}^{ent}$



LOSS FUNCTIONS

► Adversarial loss



LOSS FUNCTIONS

- ▶ Adversarial loss

- ▶ 판별기 D_i 는 다음의 손실 함수로부터 학습:


- ▶
$$\mathcal{L}_{D_i} = \mathbb{E}_{h_i \sim P_{data,E}} [-\log D_i(h_i)] + \mathbb{E}_{z_i \sim P_{z_i}, h_{i+1} \sim P_{data,E}} [-\log (1 - D_i(G_i(h_{i+1}, z_i)))]$$

- ▶ 생성기 G_i 는 판별기 D_i 를 속이기 위해 다음의 손실 함수로부터 학습:

- ▶
$$\mathcal{L}_{G_i}^{adv} = \mathbb{E}_{h_{i+1} \sim P_{data,E}, z_i \sim P_{z_i}} [-\log(D_i(G_i(h_{i+1}, z_i)))]$$

LOSS FUNCTIONS

- ▶ Conditional loss
- ▶ 인코더로부터 고레벨 표현을 복구



LOSS FUNCTIONS

- ▶ Conditional loss


- ▶ $\mathcal{L}_{G_i}^{cond} = \mathbb{E}_{h_{i+1} \sim P_{data, E}, z_i \sim P_{z_i}} [f(E_i(G_i(h_{i+1}, z_i)), h_{i+1})]$

- ▶ f 는 거리를 구하는 함수

- ▶ 논문에서는 Euclidean distance

LOSS FUNCTIONS

► Entropy loss



LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ Conditional loss를 단순히 추가하는 것은 또다른 이슈를 가져옴
 - ▶ 생성자 G_i 가 노이즈 z_i 를 무시하도록 학습하고
 - ▶ h_{i+1} 로부터 \hat{h}_i 를 결정론적으로 생성하도록 학습함

LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ 이러한 문제는 conditional GAN에서 종종 있어왔던 문제
- ▶ 어떻게 해결할 수 있을까?
 - ▶ 생성기에 노이즈를 더함
 - ▶ 그러나 conditional Generator가 노이즈를 무시하게 되면서 실패
- ▶ 아직까지 이를 잘 다루는 정석적인 방법은 없음

LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ 이 문제를 다루기 위해
 - ▶ 조건부 엔트로피(conditional entropy) $H(\hat{h}_i | h_{i+1})$ 가 가능한 높아야(~ 1) 함
- ▶ 조건부 엔트로피 $H(Y | X)$
 - ▶ 어떤 확률변수 X 가 다른 확률변수 Y 의 값을 예측하는데
 - ▶ 도움이 되는지(~ 0)를 측정할 수 있는 방법

LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ 그러나 $H(\hat{h}_i | h_{i+1})$ 를 직접 최대화하기는 어렵기 때문에
- ▶ 대신에 조건부 엔트로피의
 - ▶ Variational lower bound를 최대화

LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ 보조(Auxiliary) 네트워크 Q_i 사용
 - ▶ True posterior인 $P_i(z_i | \hat{h}_i)$ 를 추정
 - ▶ 특징 \hat{h}_i 가 주어졌을 때 z 가 관측될 확률

LOSS FUNCTIONS

- ▶ Entropy loss
- ▶ $Q_i = (z_i | \hat{h}_1)$
 - ▶ 대부분의 파라미터를 D_i 와 공유

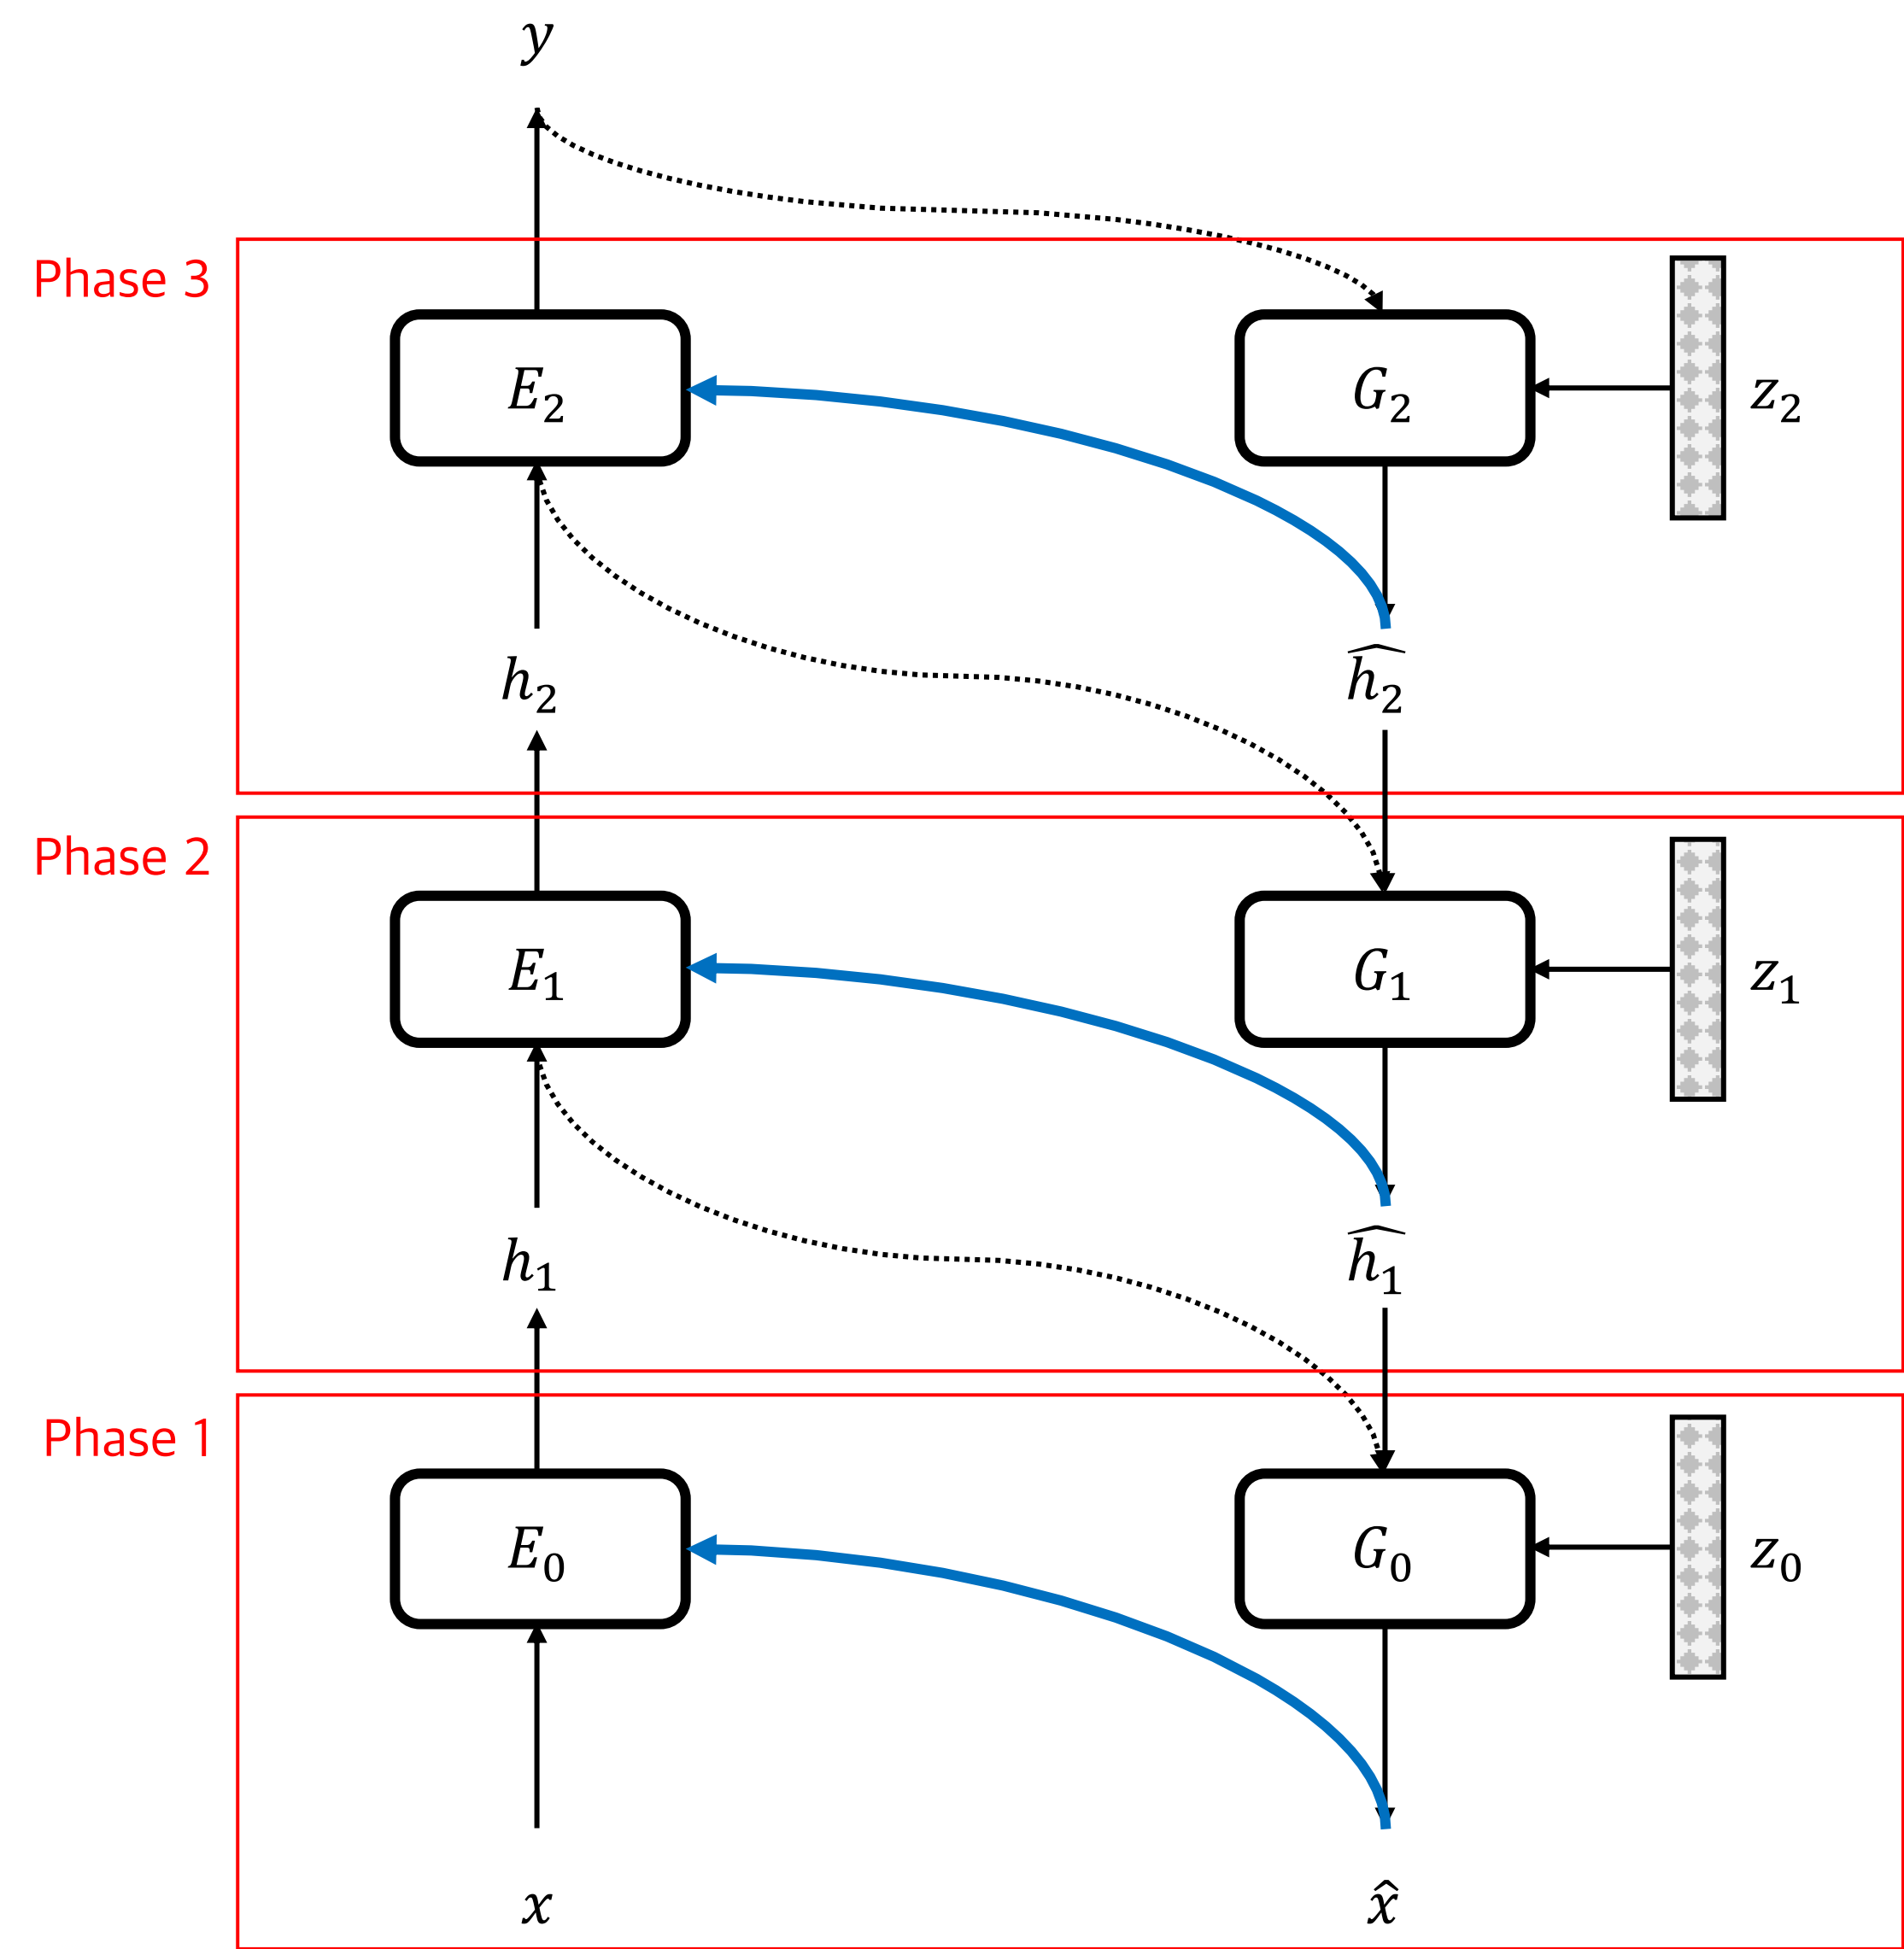
LOSS FUNCTIONS

- ▶ Entropy loss

- ▶ $\mathcal{L}_{G_i}^{ent} = \mathbb{E}_{z_i \sim P_{z_i}} [\mathbb{E}_{\hat{h}_i \sim G_i(\hat{h}_i | z_i)} [-\log Q_i(z_i | \hat{h}_i)]]$

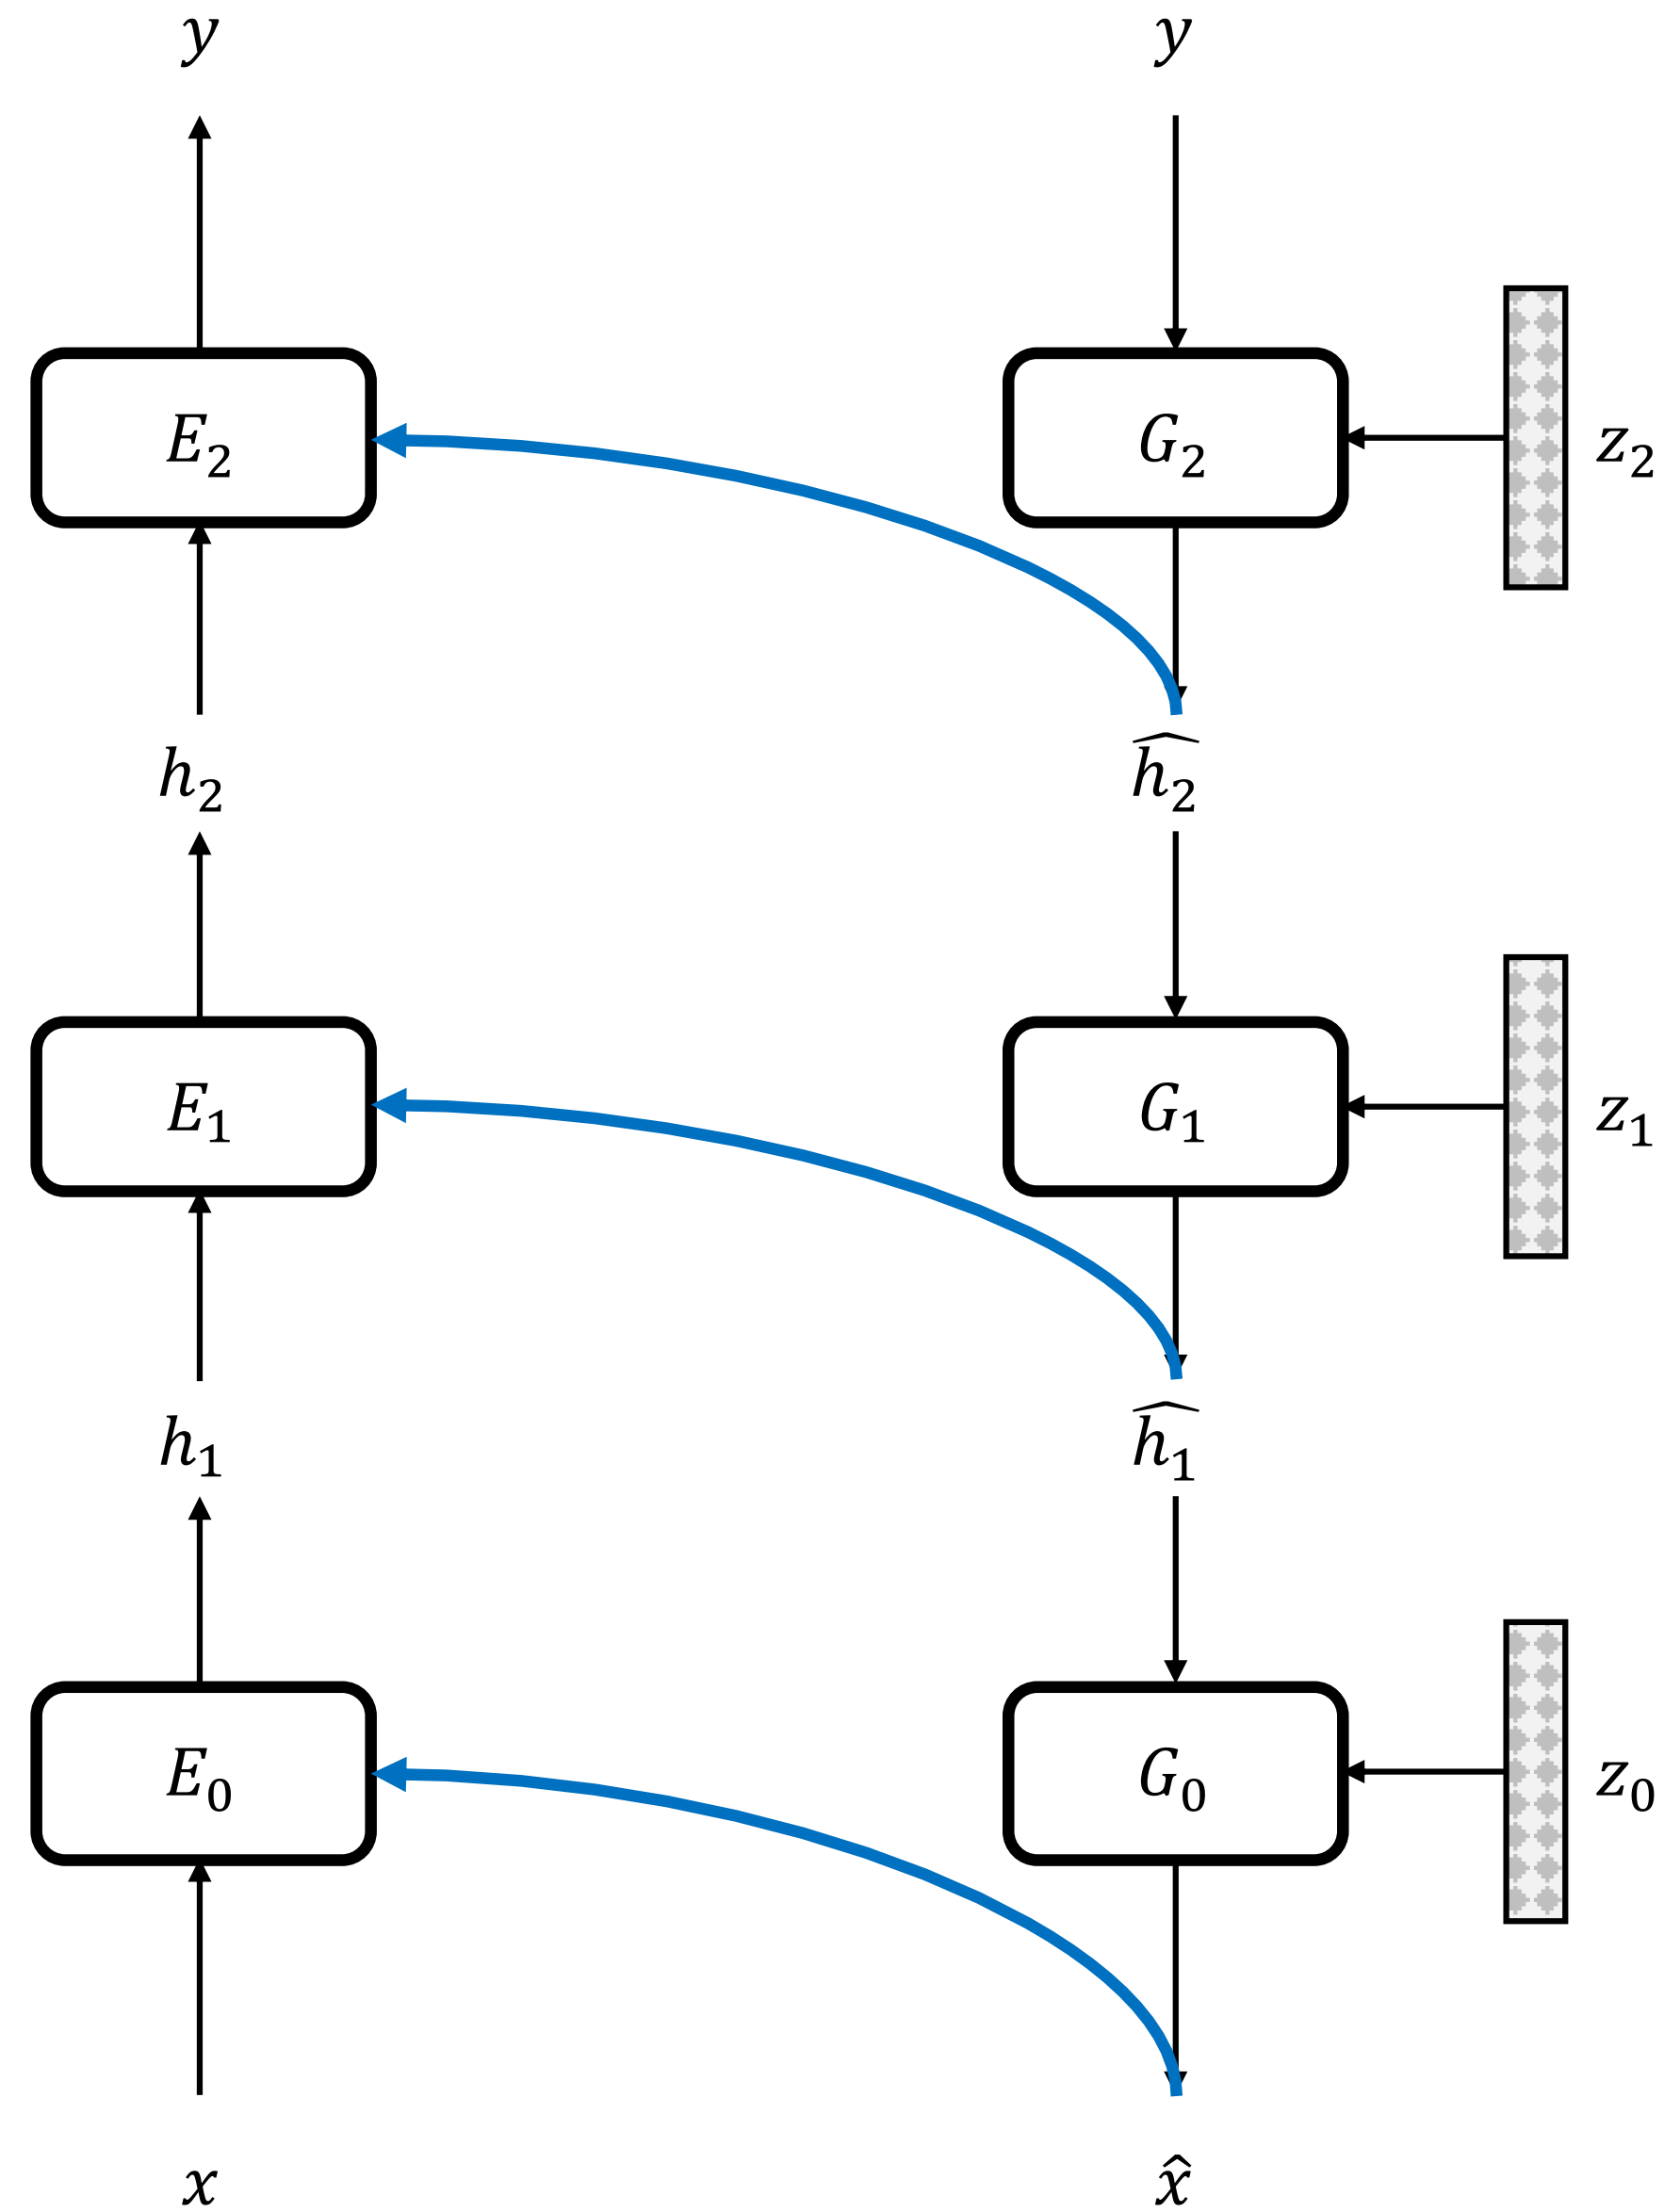
SUMMARY

- ▶ 1. 각 GAN의 독립적 학습



SGAN TRAIN


► 2. Joint training



TEST

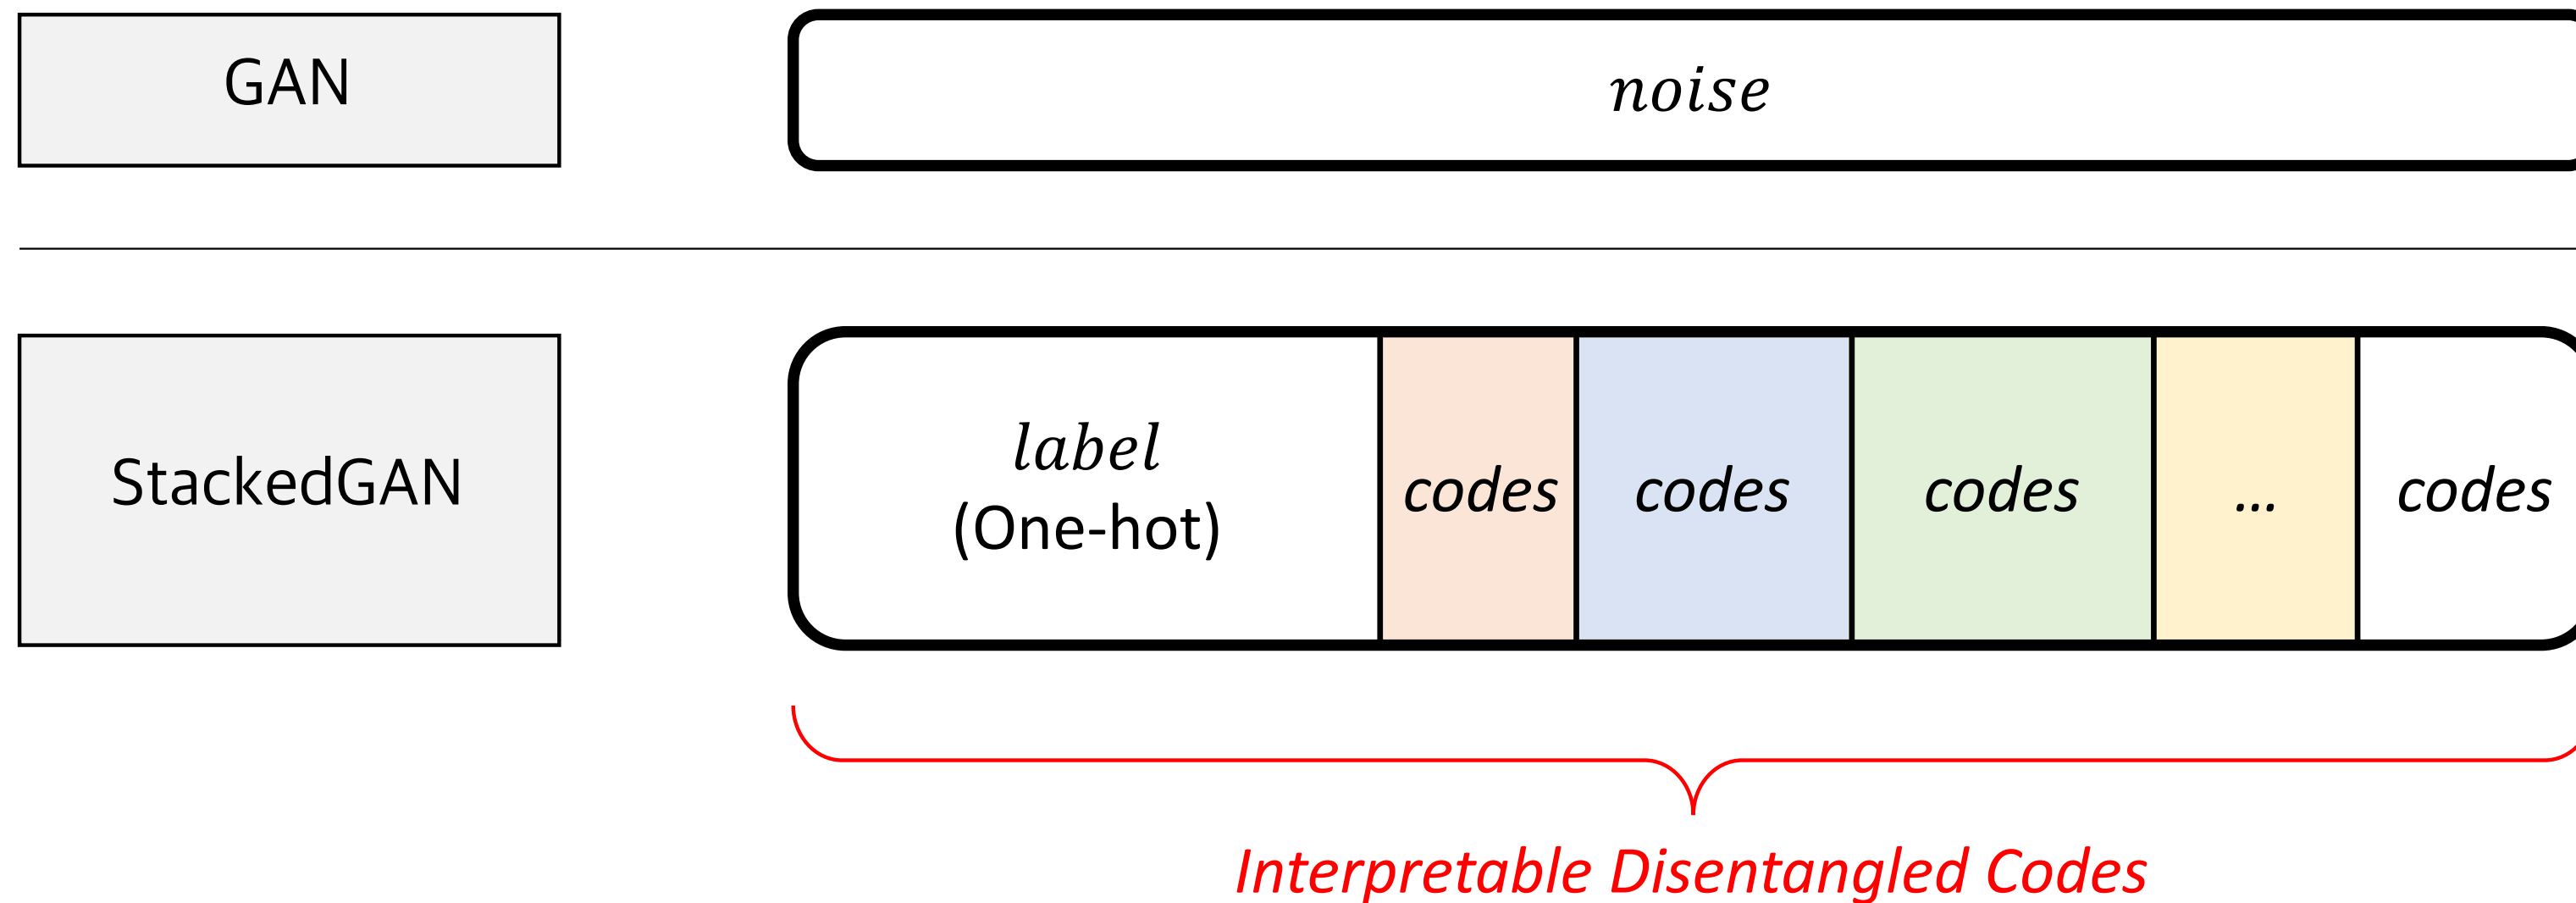
SGAN TEST

- ▶ 레이블 y 의 이미지 생성



SGAN TEST


- ▶ 레이블 y 의 이미지 생성



RESULTS

RESULTS

► MNIST




(a) SGAN samples (conditioned on labels) (b) Real images (nearest neighbor)

RESULTS

► MNIST



(c) SGAN samples (conditioned on generated $fc3$ features)



(d) SGAN samples (conditioned on generated $fc3$ features, trained *without* entropy loss)

CONCLUSION

DISCUSSION AND FUTURE WORK

- ▶ SGAN
 - ▶ Top-down 접근법
- ▶ 이미지 분포를 추정하는 어려운 문제를
 - ▶ 상대적으로 쉬운 여러 문제로 분할

DISCUSSION AND FUTURE WORK

- ▶ GAN이 노이즈를 무시하는 문제를 해결
 - ▶ Entropy Loss
 - ▶ 이는 다른 솔루션에도 쓰일 수 있음

STACKEDGAN

DISENTANGLED REPRESENTATIONS